# Trabajo 2
# Datos

## SR
## Sistemas Recomendadores

Official Master's Degree in Artificial Intelligence,
Pattern Recognition and Digital Imaging

MIARFID

# Objetivos

Los elementos a recomendar (ítems) son películas del dataset "**the movies dataset**"

El objetivo es conseguir una lista de ítems recomendados adaptada al usuario

Para ello, se calcula un ratio de interés del usuario en cada ítem

Se recomiendan los ítems de mayor ratio

# Objetivos

El objetivo de esta parte del trabajo es

- Preparar la forma en la que se almacenan los datos de los ficheros del dataset
- Definir las estructuras de datos necesarias para el funcionamiento del recomendador

# Dataset

El dataset se ha obtenido del siguiente enlace:
https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset

Se proporcionan dos versiones del dataset

- Original
- Procesada: se elimina cierta información y se eliminan películas

Ambas versiones se basan en películas de Imdb

## The Movies Dataset

Metadata on over 45,000 movies. 26 million ratings from over 270,000 users.

# Dataset

Se recomienda usar la versión procesada

Ficheros csv que contienen parte de los datos del dataset

- Se han eliminado las películas de habla no inglesa
- Se han eliminado aquellas películas que no estaban puntuadas
- Se han eliminado del fichero de keywords aquellas películas que no tenían keywords o que los keywords estaban en idioma diferente al inglés
- Codificados UTF-8

Esto supone que habrá películas que aparezcan en algunos ficheros que no existan en otros

- No se deben recomendar películas que no estén en el fichero películas.csv

# Dataset: clasificación y etiquetas

# Ficheros del dataset: clasificación

Las películas están clasificadas en 20 géneros

El fichero géneros.csv contiene estos datos

En el fichero aparece

- Identificador
- Identificador en el dataset
- Genero en ingles
- Género en castellano

| id | IdDataset | Genero | GeneroSP |
|---|---|---|---|
| 0 | 12 | Adventure | Aventura |
| 1 | 14 | Fantasy | Fantas¡a |
| 2 | 16 | Animation | Animaci¢n |
| 3 | 18 | Drama | Drama |
| 4 | 27 | Horror | Terror |
| 5 | 28 | Action | Acción |
| 6 | 35 | Comedy | Comedia |
| 7 | 36 | History | Historica |
| 8 | 37 | Western | Oeste |
| 9 | 53 | Thriller | Suspense |
| 10 | 80 | Crime | Crimen |
| 11 | 99 | Documentary | Documental |
| 12 | 878 | Science Fiction | Ciencia ficción |
| 13 | 9648 | Mystery | Misterio |
| 14 | 10402 | Music | Musical |
| 15 | 10749 | Romance | Romance |
| 16 | 10751 | Family | Familiar |
| 17 | 10752 | War | Guerra |
| 18 | 10769 | Foreign | Extranjera |
| 19 | 10770 | TV Movie | TV |

# Ficheros del dataset: etiquetas

Además, las películas tienen asociadas etiquetas que han dado los usuarios

Se encuentran en el fichero **keyword.csv**

No todas las películas tienen etiquetas

Cada película tiene un máximo de 12 etiquetas (en el dataset original hay más)

El fichero contiene

- Código de la película
- Nº de etiquetas
- Tantas columnas como etiquetas

| id | contador | keyword | keyword | keyword |
|---|---|---|---|---|
| 2 | 7 | underdog | prison | factory worker |
| 3 | 4 | salesclerk | helsinki | garbage |
| 5 | 9 | hotel | witch | bet |
| 6 | 5 | chicago | drug dealer | boxing match |
| 11 | 12 | android | galaxy | hermit |

# Dataset: Ítems

# Ficheros del dataset: peliculas.csv

27.840 películas (original 45.000)

- Son las películas del dataset original de habla inglesa
- Se han eliminado también las películas no clasificadas y las que no han sido puntuadas por ningún usuario
- Contiene únicamente los datos del dataset del fichero **movies_metadata.csv** que se consideran interesantes (y se han separado por columnas)

# Ficheros del dataset: Peliculas.csv

## Contiene

- Identificador de la película
- Identificador en Imdb: si se busca dentro de imdb con este identificador, se accede a los datos
- Título
- Path al poster de la película: http://www.omdbapi.com/
- Puntuación media de los usuarios (en el momento en el que se creó el dataset)
- Número de puntuaciones de usuarios (permite saber lo fiable que es la puntuación media)
- Número de géneros en los que está clasificada (una película puede estar clasificada en más de un género)
- Código de los géneros en los que está clasificada

# Dataset:

# Puntuaciones de usuarios

# Ficheros del dataset: ratings

## Fichero de ratios

- Ratings_small.csv
  - Contiene 100.004 puntuaciones de usuarios a películas. Los usuarios van del 1 al 671
  - Contiene
    - Identificador de usuario
    - Identificador de película
    - Puntuación: valor float entre 0.5 y 5

Se ha adjuntado otro fichero Ratings.csv, pero podéis usar el pequeño

# Ficheros del dataset

El dataset no contiene datos de usuarios

Problema para la recomendación

- No se puede usar el SR Demográfico

# División del dataset

# División de los datos del dataset

## Training set

Datos con los que se entrena el sistema. Simula la interacción de los usuarios con el sistema, hasta el momento actual

## Test set

Usado para obtener resultados sobre la bondad de la recomendación ofrecida

# División de los datos del dataset

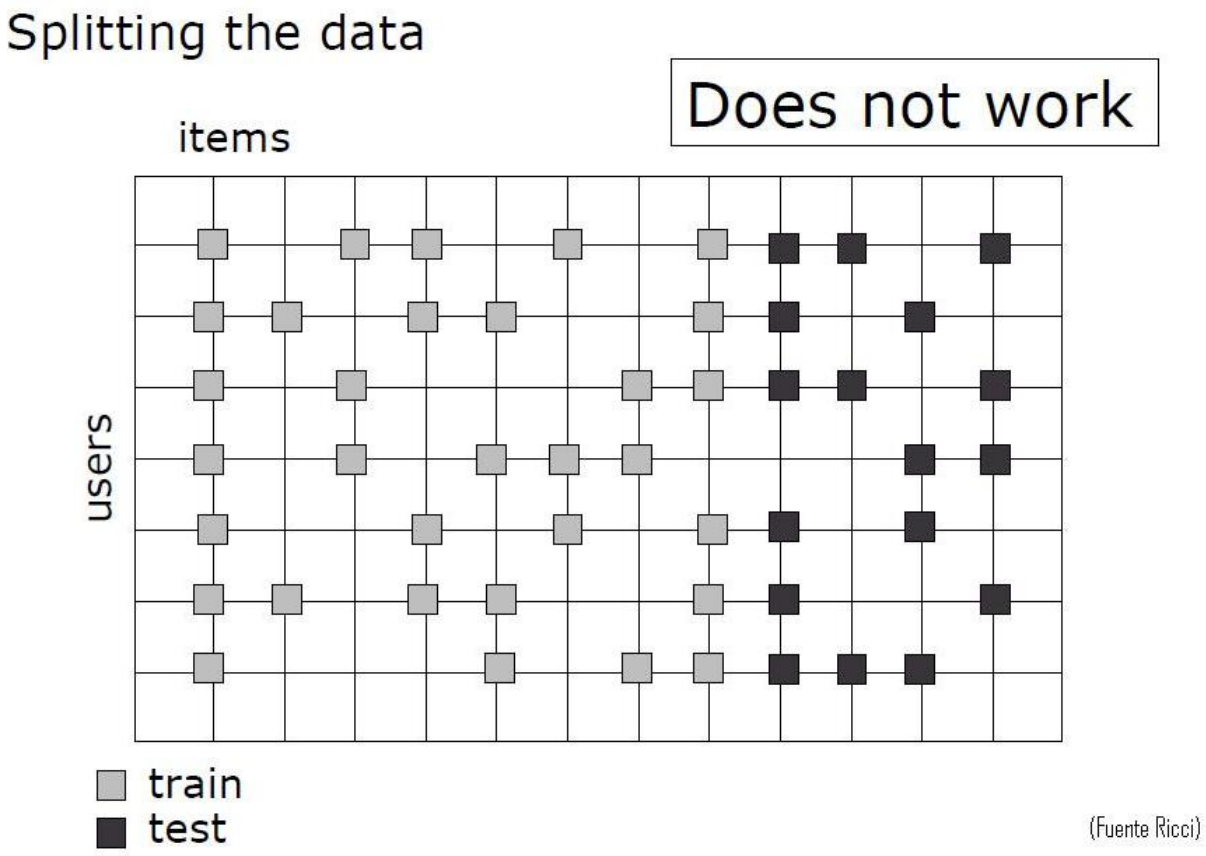


(Fuente Ricci)

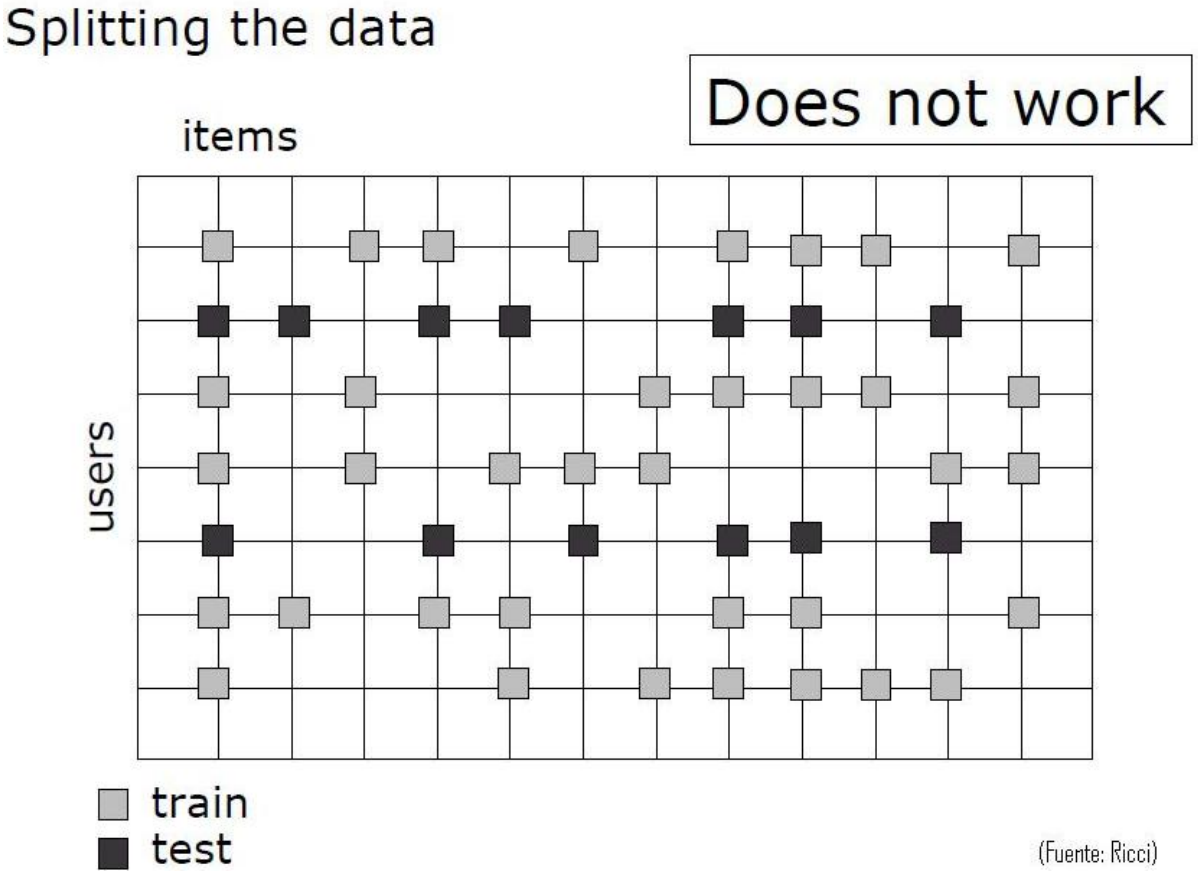


(Fuente: Ricci)

# División de los datos del dataset

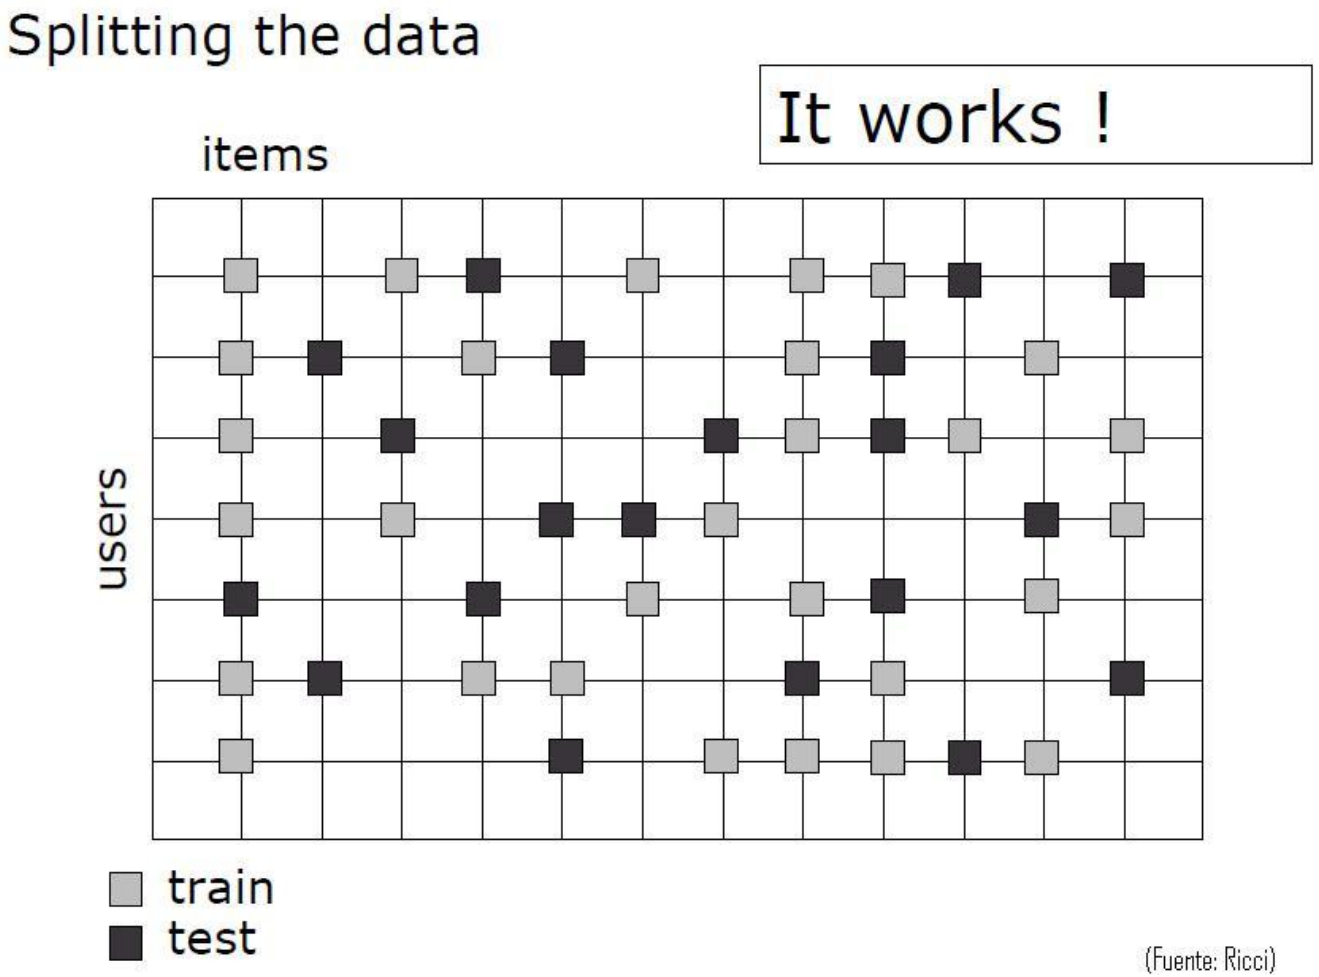


(Fuente: Ricci)

# División de los datos del dataset

## Hacer la división del dataset

- Base o entrenamiento: 70%
- Test: 30%

# Perfil de usuario

# Perfil de usuario

Identificador de usuario

Modelo de preferencias del usuario

Preferencias

Histórico de interacción del usuario con el sistema

Conjunto de ítems puntuados por el usuario (y su ratio) del dataset de entrenamiento

Información interna del SR

Información que el SR calcula, y que facilita el proceso de recomendación: vecinos,…

# Perfil de usuario: identificador

Identificador de usuario

Se crea un perfil de usuario por cada uno de los usuarios que han puntuado ítems

# Perfil de usuario: modelo de preferencias

Contiene el grado de interés del usuario en cada una de los 20 géneros de películas

Se puede usar un vector, por ejemplo, donde la posición 0 represente el género 12,… y la posición 19, el género 10770

| 0 | 20 | 50 | | 90 |
|---|---|---|---|---|
| 0 | 1 | 2 | … | 19 |

| id | IdDataset | Genero | GeneroSP |
|---|---|---|---|
| 0 | 12 | Adventure | Aventura |
| 1 | 14 | Fantasy | Fantasia |
| 2 | 16 | Animation | Animaci¢n |
| 3 | 18 | Drama | Drama |
| 4 | 27 | Horror | Terror |
| 5 | 28 | Action | Acción |
| 6 | 35 | Comedy | Comedia |
| 7 | 36 | History | Historica |
| 8 | 37 | Western | Oeste |
| 9 | 53 | Thriller | Suspense |
| 10 | 80 | Crime | Crimen |
| 11 | 99 | Documentary | Documental |
| 12 | 878 | Science Fiction | Ciencia ficción |
| 13 | 9648 | Mystery | Misterio |
| 14 | 10402 | Music | Musical |
| 15 | 10749 | Romance | Romance |
| 16 | 10751 | Family | Familiar |
| 17 | 10752 | War | Guerra |
| 18 | 10769 | Foreign | Extranjera |
| 19 | 10770 | TV Movie | TV |

| 0 | 20 | 50 | | 90 |
|---|---|---|---|---|
| 0 | 1 | 2 | … | 19 |

# Perfil de usuario: modelo de preferencias

## Usuario del dataset

Inferir las preferencias de las puntuaciones de películas del fichero de entrenamiento

## Usuario registrado

Se piden las preferencias en el momento del registro

# Perfil de usuario: modelo de preferencias de usuarios del dataset

No disponemos de información sobre los gustos del usuario, por tanto habrá que inferirlo de las películas que ha puntuado

Aconsejable convertir las puntuaciones del dataset a valores entre 0 y 100

Si un usuario no ha puntuado películas de esa categoría o si las ha puntuado mal, poner un 0

Decidir a partir de que valor se considera puntuar favorablemente y desfavorablemente

Datos a tener en cuenta para obtener el ratio de interés del usuario en la preferencia

- Nº de películas puntuadas clasificadas en la preferencia
- Puntuaciones dadas a cada película

| 0 | 20 | 50 | | 90 |
|---|---|---|---|---|
| 0 | 1 | 2 | … | 19 |

# Perfil de usuario: preferencias

Usar los datos de entrenamiento

Usar las películas que ha puntuado favorablemente

Obtener cuales son las categorías en las que están clasificadas esas películas

Obtener el ratio de interés del usuario en la categoría

| | | | | |
|---|---|---|---|---|
| **0** | **20** | **50** | | **90** |
| 0 | 1 | 2 | … | 19 |

# Perfil de usuario: histórico

Histórico de interacción del usuario con el sistema

Usar solo el fichero de entrenamiento

Almacenar en el histórico las películas vistas por el usuario, junto con su puntuación

La puntuación es un valor entre 0.5 y 5

# Perfil de usuario: información interna

## Información interna del SR

- Los SR necesitan almacenar información para posteriormente, calcular la recomendación
- Facilita y hace más rápido el proceso de recomendación
- Se va a utilizar, sobre todo, en el SR Colaborativo
  - Contiene la información de los usuarios que son vecinos del usuario actual (usuarios con mayor grado de afinidad)
- Inicialmente, no hay información interna

# Perfil de usuario: información interna

## Información interna del SR Colaborativo: vecinos

- Número de vecinos del usuario
- Para cada vecino
  - Identificador
  - Grado de afinidad con el vecino (valor entre 0 y 100)

```
// Vecino
typedef struct
{
    int id_vecino, afinidad;
} vecino;
```

```
// Recomendación colaborativa
int num_vecinos;
vecino vecinos[MAX_VECINOS];
```

# Lista de ítems recomendados

# Resultado de la recomendación

Lista de ítems recomendados a un usuario

- Lista que contiene todas las películas que el usuario no ha visto (no están en su histórico)

Lista de ítems recomendados para un grupo

- Lista que contiene todas las películas que ningún usuario del grupo ha visto (no están en sus históricos)

# Resultado de la recomendación

## Lista de ítems recomendados

- Para cada película debe aparecer:
  - Identificador
  - Ratio de interés del usuario en la película (calculado por la recomendación)
- La lista debe estar ordenada por ratio de interés (de mayor a menor)
- La interfaz de la aplicación mostrará por pantalla los N primeros elementos de la lista (el valor de N lo decidís vosotros)

# MUY IMPORTANTE

Al haber eliminado películas del fichero películas.csv, el resto de ficheros pueden hacer referencia a películas que no existen

Cuando los datos se hayan introducido en la aplicación, no pueden haber datos inconsistentes

# ¿Qué hacer ahora?

# Datos

- Dividir el fichero de ratings en entrenamiento y test
- Crear y rellenar los perfiles de usuario
- Almacenar los datos de las películas